

SimCLR 数据增强消融实验简报

基于 CIFAR-10 子集的 100 Epoch 对比分析

摘要

本文将仓库中的 README 与实验结果文件压缩整理为一份短论文式报告，讨论在 CIFAR-10 的 5000 张训练样本子集上，不同数据增强组件对 SimCLR 表示学习效果的影响。实验比较了四种增强方案：完整增强流水线 (**baseline**)、去掉高斯模糊 (**no_blur**)、去掉颜色扰动 (**no_color_jitter**) 和去掉随机灰度化 (**no_grayscale**)。所有实验均在相同设置下使用 ResNet-18 训练 100 个 epoch，并通过冻结编码器的线性评估检验下游分类表现。结果显示，**no_color_jitter** 在对比学习训练指标上显著领先，但在线性评估中反而最差；相反，**no_grayscale** 和 **no_blur** 的下游精度都优于 **baseline**。这一结果说明，SimCLR 预训练阶段的优化指标并不能直接作为表示质量的可靠代理。

1 引言

本次实验关注一个非常具体的问题：在其他训练条件保持不变的前提下，**ColorJitter**、**GaussianBlur** 和 **RandomGrayscale** 这三个常见增强组件，究竟如何影响 SimCLR 的预训练表现，以及更重要的下游分类效果。这个问题看似简单，但它直接关系到我们应当如何理解对比学习中的“训练得更好”。

仓库中的原始 README 已经给出了完整实验记录，但其中既包含报告性内容，也包含交接与复现信息。为了让结论更适合展示，这里将信息重新组织为论文式结构，突出研究问题、实验设置、结果比较和方法论结论。

2 实验设置

实验数据集为 CIFAR-10，主干网络为 ResNet-18，projection head 维度为 128。所有实验统一使用 batch size 256、temperature 0.07、learning rate 0.0003、weight decay 1×10^{-4} 、每张图像 2 个 views、随机种子 0，并训练 100 个 epoch。为了控制成本，本次预训练只使用 5000 张训练图像，运行设备为 CPU，data loader workers 设为 0。

下游评估采用冻结编码器加线性分类器的方式，在 5000 张 CIFAR-10 训练图像上训练线性层，并在 10000 张测试图像上报告测试精度。这样的设置可以较直接地反映预训练表示是否真正有利于分类任务。

基线增强流水线为：

```
RandomResizedCrop + RandomHorizontalFlip +
RandomApply(ColorJitter, p=0.8) + RandomGrayscale(p=0.2) +
GaussianBlur + ToTensor
```

本次消融每次只改动其中一个组件，因此四组实验之间的主要差异只来自增强策略本身。

3 结果

3.1 预训练阶段结果

表 1 汇总了四组实验在 SimCLR 训练结束时的核心指标。若只看对比学习任务自身，`no_color_jitter` 的表现几乎是压倒性的：它的最终 loss 最低，contrastive top-1 和 top-5 也显著高于其他方案。

表 1: SimCLR 预训练阶段最终指标

增强方案	Final loss	Contrastive top-1	Contrastive top-5
baseline	3.892488	28.4951	46.2685
no_blur	3.783522	30.0884	47.9235
no_color_jitter	1.784125	63.2299	80.0781
no_grayscale	3.476313	30.7771	51.7167

注：这里的 contrastive top-1 / top-5 反映的是对比学习任务内部把正样本排到前列的能力，并不是 CIFAR-10 分类准确率。




图 1: 四组增强方案在预训练阶段的 contrastive top-1 与 loss 变化曲线

从图 1 可以进一步看到，`no_color_jitter` 在整个训练过程中都拥有更快的收敛速度和更高的对比学习指标。如果只停留在预训练阶段，我们很容易得出“去掉颜色扰动更好”的结论。

3.2 线性评估结果

真正关键的结果出现在下游线性评估中，如表 2 所示。最佳 test accuracy 来自 `no_grayscale`，达到 44.92%，比 `baseline` 的 43.57% 提高了 1.35 个百分点；`no_blur`

也达到 44.56%，比基线高 0.99 个百分点。相反，训练指标最亮眼的 `no_color_jitter` 测试精度只有 42.07%，反而比基线低了 1.50 个百分点。

表 2: 冻结编码器线性评估结果

增强方案	Train accuracy	Test accuracy	Test top-5
baseline	71.50	43.57	89.63
no_blur	71.90	44.56	89.78
no_color_jitter	71.48	42.07	88.47
no_grayscale	72.94	44.92	89.62




图 2: 冻结编码器线性评估的测试精度对比

图 2 将这种反差展示得更加直接：`no_color_jitter` 虽然“更会做预训练任务”，但并没有学到更适合分类的表示；`no_grayscale` 和 `no_blur` 的对比学习指标并不夸张，却在下游任务中更可靠。

4 讨论

这组实验最有价值的地方，不是简单地告诉我们“哪一种增强组合赢了”，而是揭示了预训练目标与下游目标之间可能存在明显错位。`no_color_jitter` 是最典型的反例：当颜色扰动被移除之后，对比学习任务本身可能变得更容易，模型也因此更容易把正样本配对成功，于是 loss 更低、top-1 和 top-5 更高；但与此同时，模型学到的表示可能更依赖颜色线索，缺少了对颜色变化的鲁棒性，最终不利于分类泛化。

相比之下，`RandomGrayscale` 和 `GaussianBlur` 在这组设置里并没有体现出必要性，甚至略微拖累了最终测试精度。至少在 CIFAR-10、ResNet-18、100 epoch、5000 样本子集这一条件下，去掉灰度增强和去掉模糊增强都比保留完整基线更稳妥。

当然，这些结论也有边界：本次实验只使用单一随机种子，只覆盖 CIFAR-10 的 5000 样本

子集，并且在 CPU 环境下完成训练。因此，这里的结果更适合作为当前设置下的经验结论，而不是对所有 SimCLR 场景的一般定律。

5 结论

在本次实验设置下，若需要从四个编码器中优先选择后续下游任务的候选，推荐顺序为 `no_grayscale`、`no_blur`、`baseline`、`no_color_jitter`。更重要的是，这份实验给出的核心方法论结论非常明确：**SimCLR 训练阶段的优化指标和下游迁移效果之间，可能出现显著不一致，因此不能只凭预训练 loss 或 contrastive top-k 指标判断表示质量。**

6 复现实验入口

如需继续扩展本实验，仓库中的 `run_augmentation_suite.py` 用于批量运行增强消融，`plot_augmentation_training_comparison.py` 用于生成跨实验训练对比图，`run_linear_eval_suite.py` 用于执行冻结编码器线性评估并汇总结果。本文中的所有数值均来自仓库现有的 `summary.json`、`metrics.csv` 和线性评估汇总文件。